

דוח שיטות: מרשם הטענות (Claim Registry)

סקירת השיטות שנבדקו לסיווג התבטאויות משתתפים מול מאגר טענות - יתרונות, חסרונות ותוצאות

16-23 · Freedi Research יולי 2026 · ענף feat/claim-registry-improvements · נתוני הערכה: Blair, Procaccia & Tambe, *Embeddings for Preferences, Not Semantics* (2026)

תקציר. בפלטפורמת דיון, כל התבטאות חדשה של משתתף צריכה להיבדק: האם היא חוזרת על רעיון שכבר קיים, מנוגדת לו, או מציגה רעיון חדש. הבדיקה נעשית מול **מאגר טענות** - רשימה קצרה של רעיונות מובחנים שכבר עלו בדיון. דוח זה מסכם את כל השיטות שנבדקו לביצוע הסיווג הזה, על מדגם קשה של 875 "שלשות בדיקה" (התבטאות עוגן, ניסוח מחדש תואם עמדה, וניסוח כמעט זהה בעמדה הפוכה) שנועד לתפוס בדיוק את המקרה שבו ניסוח לשוני מטעה שיטות מבוססות-מרחק.

הממצא המרכזי: מודל שפה קטן שקורא את רשימת הטענות ושופט כל התבטאות (**מרשם הטענות**) מגיע לדיוק **95%** כאשר הוא בודק מול טענה בודדת בניסוחה המקורי - לעומת **0.5%** בלבד לשיטת embedding הגאומטרית שבשימוש היום. אולם ברגע שעוברים לתנאים ריאליים - טענה מתומצתת, ומאגר של כ-100 טענות ולא אחת - הדיוק יורד משמעותית, וחלק ניכר מהעבודה בדוח זה עוסק בצמצום הפער הזה, ובניסיון להוזיל את עלות הבדיקה מול מאגר גדול מבלי לפגוע בדיוק.

1 רקע: למה בכלל צריך את זה

הטכניקה הנפוצה להשוואת טקסטים - **embedding** (הפיכת משפט לנקודה במרחב רב-ממדי, והשוואה לפי מרחק) - נכשלת במקרה ספציפי וחשוב: היא מבולבלת בין "ניסוח דומה" ל"עמדה דומה". התבטאות שמנוגדת לרעיון מסוים, אך משתמשת כמעט באותן מילים, תיראה ל-embedding **קרובה יותר** לרעיון מאשר ניסוח חדש לגמרי של אותו רעיון בדיוק. במדגם ה-875 השלשות שנבדק כאן, שיטת ה-embedding שבשימוש הפרויקט הצליחה לפתור נכון פחות מ-1% מהמקרים - פחות מהטלת מטבע.

הפתרון שנבדק הוא **קורא** ולא **סרגל**: מודל שפה (LLM) שמקבל את רשימת הטענות הקיימות ואת ההתבטאות החדשה, וקובע במפורש האם ההתבטאות **מבטאת** טענה קיימת, **מתנגדת** לה, או **אינה קשורה** ("none"). זהו הבסיס לכל השיטות המתוארות להלן - ההבדלים ביניהן הם: כמה טענות מוצגות בכל בדיקה, איך הטענות מנוסחות, ואיך בוחרים אילו טענות בכלל להציג.

2 טבלת סיכום

שיטה	תיאור בקצרה	דיוק (n=875 אלא אם צוין)	הערה עיקרית
A	embedding בלבד (הבסיס הקיים)	0.5%	לא מבחין בין ניסוח לעמדה
B1	טענה בודדת, טקסט מקורי, gpt-4o-mini	95.0%	תקרת היכולת של השיטה
A2	סיון embedding + שיפוט LLM (היברידי)	95.0%	זהה ל-B1, ללא עלות נוספת

B2	טענה בודדת, מתומצתת (כפי שנשמר בפועל)	70.1%	תמצות פוגע בדיוק ב-25 נק'
B2E / B2E2	טענה מועשרת + ניסוח זהיר לעמדה	88.6% / 87.4%	משחזר את רוב מה שהתמצות איבד
D	כמו B1, על gpt-4o (מודל גדול יותר)	96.5%	1.5 נק' נוספות, פי 20 יקר יותר
C	מאגר מלא (~94 טענות), בדיקה שטוחה	36.0%	הבחירה מתוך רשימה ארוכה קשה למודל
CE / CE2	מאגר מלא, מועשר + ניסוח זהיר	53.8% / 49.6%	אותו תיקון כמו B2E, בקנה מידה מלא
CH	ניתוב דו-שלבי, נושאים שהומצאו ע"י LLM	55.8%~52.3	לא פוגע בדיוק, אך לא מצמצם מספיק
CHC	ניתוב דו-שלבי, אשכולות לפי embedding	62% (n=100, מבחן ראשוני)	משפר דיוק, עדיין לא פותר את הצמצום

"דיוק" = האחוז מהשלשות שבהן ההתבטאות התואמת סווגה נכון וגם ההתבטאות המנוגדת נדחתה נכון. שיטות CH/CHC נבדקו על תת-קבוצה חלקית של הנתונים (ראו סעיפים בהמשך).

3 שיטות ייחוס – מהי התקרה?

embedding – A בלבד (קו הבסיס)

כל משפט הופך לוקטור מספרי (embedding), וההחלטה מבוססת על מרחק קוסינוס בין הוקטורים. זו השיטה הגאומטרית שבשימוש היום ברוב מערכות ה-retrieval.

דיוק: 0.5% (n=875) · עלות: זניחה (embedding בלבד, ללא קריאת LLM)	
יתרונות	חסרונות
- זול ומהיר להפליא - לא דורש קריאת LLM כלל	לא מבחין בין "ניסוח דומה" ל"עמדה דומה" – נכשל כמעט תמיד במדגם הקשה הזה

B1 – טענה בודדת, טקסט מקורי (התקרה)

הבדיקה הפשוטה ביותר האפשרית: לכל שלשה, הטענה היחידה שמוצגת ל-LLM היא הטקסט המקורי המדויק של התבטאות העוגן (ללא תמצות). מטרתה לבדוק – האם ה-LLM בכלל מסוגל להבחין בין ניסוח תואם לניסוח מנוגד, כשאין שום דבר אחר שמפריע?

דיוק: 95.0% [93.3, 96.2] · עלות: 1,750 קריאות, כ-0.19\$ סה"כ (~0.11\$ לכל 1,000 סיווגים)	
יתרונות	חסרונות
- הדיוק הגבוה ביותר שנמדד - זול מאוד לקריאה בודדת	לא ריאלי – מניח שכבר יודעים מראש מול איזו טענה בודדת לבדוק

• אינו פותר את בעיית החיפוש במאגר גדול

A2 – סינון embedding + שיפוט LLM (ארכיטקטורת RAG)

התבנית הנפוצה בתעשייה: embedding זול בוחר רשימה מצומצמת של מועמדים, וה-LLM שופט רק בתוכה. בבדיקה זו, החלטות ה-LLM זהות ל-B1 – רק סף הסינון הגאומטרי משתנה – כך שאין עלות נוספת כלל.

דיוק: 95.0% (זהה ל-B1) • עלות: ללא עלות נוספת מעבר ל-B1

חסרונות

- תלוי בכך שהסינון הגאומטרי לא "יפסול" את הטענה הנכונה מראש (bottleneck בשכבה הראשונה)

יתרונות

- משלב זול (embedding) ומדויק (LLM) יחד
- ארכיטקטורה מוכרת ומוכחת

4 שיטות בקנה מידה של טענה בודדת – מה קורה כשהטענה מתומצתת?

B2 – טענה מתומצתת (קנונית)

בפועל, המערכת אינה שומרת את הטקסט המקורי של התבטאות כטענה – היא מייצרת ומשמרת **ניסוח קנוני קצר** (5-15 מילים). שיטה זו בודקת מה קורה כשמציגים ל-LLM את הניסוח המתומצת הזה במקום את המקור.

דיוק: 70.1% [66.9, 73.0] – ירידה של כ-25 נק' לעומת B1

יתרונות

- ריאלי – זה בדיוק מה שהמערכת שומרת בפועל
- טענות קצרות = פרומפט קטן וזול יותר

חסרונות

- התמצות משמיט ניואנס עמדה קריטי, וגורם לפגיעה חדה בדיוק

B2E / B2E2 – טענה מועשרת + ניסוח זהיר לעמדה

תיקון לבעיית B2: לצד הניסוח הקנוני הקצר, מוסיפים הסבר ציבורי ודוגמה מייצגת (exemplar) מהטקסט המקורי (B2E), ובנוסף שורת הנחיה בפרומפט שמזהירה את המודל להיזהר מהיפוכי עמדה (B2E2).

דיוק: B2E – 87.4% [85.1, 89.5] · B2E2 – 88.6% [86.3, 90.5]

יתרונות

- משחזר את רוב הדיוק שאבד בתמצות, מבלי לוותר על טענות קצרות במאגר
- הפחית טעויות "היפוך עמדה" (false merge) מ-19.3% ל-10.3%

חסרונות

- פרומפט ארוך יותר מ-B2 הבסיסי (עלות מעט גבוהה יותר)
- עדיין לא מגיע לתקרת B1

D – מודל גדול יותר (gpt-4o במקום gpt-4o-mini)

אותה בדיקה בדיוק כמו B1, על מודל שפה גדול ויקר משמעותית.

דיוק: 96.5% [95.0, 97.5] · עלות: \$3.16 סה"כ – כ-פי 20 מ-B1, עבור 1.5 נק' דיוק בלבד

יתרונות

- הדיוק הגבוה ביותר שנמדד בכלל

חסרונות

- יחס עלות-תועלת גרוע מאוד – לא מוצדק לשימוש שוטף

5 שיטות בקנה מידה מלא – מאגר של כ-100 טענות

אלה השיטות הריאליות ביותר: לכל התבטאות חדשה, קריאת LLM אחת שמציגה את כל הטענות הקיימות בשאלה (עד כ-100), ומבקשת מהמודל לבחור את המתאימה. חשוב להבהיר: זו לא מאה בדיקות נפרדות – זו קריאה בודדת עם פרומפט גדול יותר. העלות עולה, וגם הקושי של המודל להבחין בין אפשרויות רבות ודומות.

C – מאגר מלא, טענות קנוניות (בדיקה שטוחה)

דיוק (התאמה לטענת המקור המדויקת): 36.0% [32.9, 39.2] · עלות: \$0.72 סה"כ (פי ~3.8 מ-B1, אותו מספר קריאות בדיוק – הפער כולו מגודל הפרומפט)

יתרונות	חסרונות
ריאלי – כך המערכת בפועל צריכה לחפש בין הרבה טענות	פגיעה חדה בדיוק – הבחירה מתוך רשימה ארוכה של טענות דומות קשה למודל

CE / CE2 – מאגר מלא, מועשר + ניסוח זהיר

אותו תיקון שעבד עבור B2E/B2E2, מוחל עכשיו בקנה מידה מלא של מאגר שלם.

דיוק: CE2 – 53.8% [50.5, 57.1] · CE – 49.6% [46.3, 52.9]

יתרונות	חסרונות
- שיפור משמעותי לעומת C הבסיסי - זהו קו הבסיס העדכני ביותר להשוואה מול שיטות הניתוב הדו-שלבי (סעיף הבא)	עדיין רחוק מהתקרה של B1 – קושי הבחירה מתוך רשימה ארוכה לא נעלם לגמרי

6 צמצום החיפוש: ניתוב דו-שלבי (Phase 2)

הרעיון: לפני קריאת הסיווג המלאה, לחלק את הטענות ל"נושאים" רחבים (תיקיות), לזהות באיזה נושא (2-1) שייכת ההתבטאות החדשה, ולהציג ל-LLM רק את הטענות שבתוך אותם נושאים – לא את כל המאגר. מדד ההצלחה המרכזי הוא **גודל רשימת המועמדים** (יעד: פחות מ-40% מהמאגר) ו**אחוז הכניעה** – מקרים שבהם המערכת מוותרת ובודקת הכל בכל זאת (יעד: פחות מ-15%).

CH – נושאים שהומצאו על ידי LLM

ה-LLM מקבל את רשימת הטענות המלאה, ומתבקש להמציא 3-8 "נושאים" רחבים המכסים אותה.

דיוק: 52.3%-55.8% (זהה סטטיסטית ל-CE2, ללא פגיעה) · גודל רשימת מועמדים בפועל: ~53%-57% מהמאגר (יעד: >40%) · אחוז כניעה: ~20%-28% (יעד: >15%)

חסרונות

- נוטה ליצור "נושא-שק" אחד גדול שסופג 33%-76% מכל הטענות בכל מערך נתונים שנבדק – צמצום אמיתי מוגבל
- עלות הקמה: קריאת ניתוב נפרדת לכל טענה במאגר בעת הבנייה (~1 קריאה לטענה)

יתרונות

- לא פוגע בדיוק לעומת חיפוש שטוח מלא
- כשהוא עובד כמתוכנן – חוסך משמעותית באורך הפרומפט

CHC – אשכולות לפי דמיון embedding

במקום לבקש מה-LLM "להמציא" נושאים, מקבצים טענות לפי דמיון embedding בפועל (מיזוג רק כאשר הדמיון החוצה-אשכולות עולה על סף מסוים) – כך שקבוצה הומוגנית אמיתית לא מתפצלת בכוח, וקבוצה שונה אמיתית לא מתמזגת בכוח. תוצאה חשובה: יש להריץ את ה-embedding על **טקסט הטענה בלבד**, ללא תחילית השאלה – הוספת השאלה לכל טענה (שיטה שמשמשת בשלבים אחרים בפרויקט) מכווצת את כל הדמיונות לטווח צר וחסר תועלת.

מבחן ראשוני על 100 שלשות, מערך הנתונים הקשה ביותר (הכי הרבה טענות ב"נושא" אחד): דיוק 62% (לעומת 52% בשיטת CH על אותן שלשות) · אחוז כניעה 39% (לעומת 43.5%) · גודל רשימת מועמדים: 66.8% – **ללא שינוי** לעומת CH

חסרונות

- לא פתר את בעיית הצמצום במקרה שנבדק: כ-69 מתוך 100 הטענות נמצאות באמת באשכול סמנטי הדוק אחד – ממצא אמיתי מה-embedding, לא תוצר לוואי של השיטה. גם ניתוב "נכון" לאשכול הזה עדיין בודק רוב המאגר
- דורש כיוונון של סף הדמיון (נבדק אמפירית: 0.6 ומטה כמעט חסר משמעות עבור מערך הנתונים)

יתרונות

- משפר דיוק ואחוז כניעה בבירור
- לא כופה חלוקה מלאכותית – מכבד קבוצות אמיתיות, גדולות כקטנות
- אינו משאיר טענות "ללא שיוך" (שנכללות תמיד בכל בדיקה) – כל אשכול, גם בן טענה אחת, הופך לנושא בר-ניתוב
- עלות הקמה נמוכה יותר מ-CH – שיוך הטענות נובע ישירות מהאשכול, ללא קריאת LLM

7 כיוון שלא נבדק במלואו: התאמה מול "טענה בודדת" ברמת הטענות עצמן

רעיון שעלה לקראת סוף העבודה ולא מומש עדיין: להשתמש במנגנון B1 עצמו (95% דיוק) כדי לבנות את שכבת הנושאים - במקום דמיון embedding, לבדוק לכל טענה חדשה (בעת הבנייה) האם היא "מבטאת" אשכול קיים, יחסית לנציג שלו, באמצעות אותה קריאת סיווג שכבר הוכחה כאמינה. זה עקרונית פותר את מגבלת ה-embedding (שאינו מבחין בין "אותו נושא" ל"אותו רעיון בדיוק"), במחיר עלות הקמה גבוהה יותר (השוואה הדרגתית מול נציגי אשכולות קיימים, לא כל הזוגות) - אך עדיין הרבה יותר זול מהשוואת כל זוג טענות אפשרי.

8 מסקנות

1. **מרשם הטענות (LLM כקורא) עובד היטב** - הפער מול embedding גרידא הוא עצום (95% מול 0.5%), וזו ההצדקה הבסיסית לכל הגישה.

2. **תמצות הטענות עולה דיוק**, אך ניתן לשחזר רוב הפער (מ-70.1% ל-88.6%) על ידי הוספת הסבר ודוגמה, וניסוח זהיר יותר לגבי היפוכי עמדה.

3. **חיפוש במאגר מלא עולה דיוק נוסף** - הבחירה מרשימה ארוכה קשה יותר למודל מבחירה מרשימה קצרה, גם כשהטענות מנוסחות היטב.

4. **ניתוב דו-שלבי (חלוקה לנושאים) לא פוגע בדיוק, אך טרם השיג את יעד הצמצום**. שתי הגישות שנבדקו (המצאת נושאים ע"י LLM, ואשכול לפי embedding) נתקלות באותה תופעה: בחלק ניכר מהדיונים יש "ליבה" סמנטית אחת גדולה שרוב הטענות שייכות אליה באמת - וזה לא ניתן לפתרון על ידי שיפור אופן בניית הנושאים בלבד.

5. **הצעד הבא הסביר**: לטפל בקבוצה הגדולה-אך-אמיתית אחרת - להציג למסווג רק דוגמאות נציגות מתוכה במקום את כל חבריה, במקום לנסות לפרק אותה מלאכותית; ו/או לבדוק אשכול מבוסס-LLM (בעלות מתונה, לא כל הזוגות) במקום אשכול מבוסס-embedding.

מבוסס על: `scientific-research/20206-07-16-Claim-regestry/` - `RESULTS.md`, `TEST_REPORT.md`, `TESTING_HANDOFF.md`, ותוצרי ההרצה בענף `feat/claim-registry-improvements`. מדד "דיוק" בכל השיטות: אחוז השלשות שבהן ההתבטאות התואמת סווגה כמבטאת את טענת המקור המדויקת (ברמת ביטחון ≥ 0.6) וגם ההתבטאות המנוגדת לא סווגה כך.